

# 熱力学的遺伝アルゴリズムおよび Bi-LSTM + VSE に基づくコーディネートスケジュールの最適化

Optimize the outfit schedule utilizing the thermodynamical genetic algorithm and Bi-LSTM + VSE

林 美衣<sup>\*1</sup>    森 直樹<sup>\*2</sup>  
Mie Hayashi    Naoki Mori

<sup>\*1</sup>大阪府立大学  
Osaka Prefecture University

In recent years, the application of artificial intelligence technology to the fashion field has attracted attention. This research proposes a method of optimizing the fashion outfit schedule by acquiring the performance scores of outfits from a deep learning model that learns outfits composed of images of multiple clothes and accessories. In the proposed method, first, input the outfit that combines the clothes you have into the already learned Bi-LSTM + VSE model, and get the performance scores. Based on the scores, I created a list consisting of multiple outfits, that is, a mix and match clothing plan, using the Thermodynamical Genetic Algorithm (TDGA). We impose restrictions that the same outfit should not be used during the period, the same item should not be used within 3 days, and there should be no items that have never been used during the period. These restrictions make it possible to create a mix and match clothing plan while considering diversity. To confirm the effectiveness of the proposed method as a recommendation system, numerical experiments were carried out taking real fashion item data as examples.

## 1. はじめに

近年、機械学習の発展を背景として人工知能 (Artificial Intelligence : AI) が注目を浴びている。その中でも特に画像認識の分野は実社会における応用範囲が広く、関連研究が積極的になされている。AI は単純なパターン認識では人間の能力を凌駕する一方で、人間の感性に関する分野への AI の適用はいまだに難しく重要な課題とされている。

以上の点を背景として本研究は、複数の衣服やアクセサリの画像で構成されたコーディネート学習したモデルからコーディネートの出来栄え点を獲得し、それを用いてファッションコーディネートスケジュールを最適化する手法を提案する。また数値実験により、提案手法がユーザが購入を検討しているアイテムを定量的に評価し、どのアイテムを買うべきか推薦するツールとしても活用できることを示す。

## 2. 関連研究

### 2.1 先行研究

コーディネートの出来栄えを評価する先行研究として、Hanらの研究 [Han 17] について述べる。図 1 に示すように、畳み込みニューラルネットワークにより抽出したファッションアイテム画像の特徴量を Long short-term memory (LSTM) [Gers 99] の入力とし、次のアイテムを予測できたか否かで評価するモデルを提案している。

### 2.2 データセット

先行研究 [Han 17] で用いられているデータセット「Polyvore Dataset」について述べる。Polyvore は EC サイトの服の画像を、ユーザがコラージュして投稿するサービスで、同サイトの投稿を収集したものが Polyvore Dataset である。

Polyvore Dataset ではアイテムがおおよそ種別の順番に並んでおり、トップス、ボトムス、靴、アクセサリの順になっている。




図 1: 先行研究 [Han 17] (図 2 を参照) のモデル概略図

る。トップスの中でも、シャツや T シャツはアウターの前に来るように配置されている。

また、アクセサリも概ねハンドバッグ、帽子、メガネ、時計、ネックレス、イヤリングなどの順に並んでおり、トップスから順に index が振られていく。このため index が大きくなるに従って、アイテム種別はだまかに定まるが、一意には対応していない。

このデータセットには 21,889 のコーディネートがある。1 つのコーディネートに含まれるアイテムの数は各コーディネートによって異なるため、アイテム数の上限が 8 になるように揃えられている。

### 2.3 適用事例

2.1 で示した先行研究のモデルでコーディネートを学習することによって、以下のような問題を解くことができる。

- コーディネートの出来栄えを採点する。
- コーディネートに欠けているアイテムを選択する。
- 与えられたファッションアイテムに合ったコーディネートを生成する。

連絡先: 林 美衣, 大阪府立大学 工学研究科, 大阪府堺市中区  
学園町 1-1, hayashi@ss.cs.osakafu-u.ac.jp

### 3. 提案手法

先行研究では 1 つのコーディネートについてののみ検討・評価していたため、複数の期間にわたるコーディネートスケジュールについては言及されていなかった。そこで本研究では、ファッションアイテムの定量化および評価に先ほどの先行研究のモデルを用いてコーディネートの出来栄え点を獲得し、遺伝的アルゴリズムを用いて複数のコーディネートからなる着まわしスケジュールを作成するシステムを提案する。

### 4. 要素技術

#### 4.1 遺伝的アルゴリズム

遺伝的アルゴリズム (Genetic Algorithm : GA) とは生物進化における遺伝と適者生存における自然淘汰の仕組みを取り入れた最適化手法である。ここでは本研究で用いた GA の設定について説明する。まずランダムに初期化された  $N$  個の個体からなる初期集団を発生させ、各個体の適応度を計算する。

GA では一般的に次の遺伝的操作が用いられる。

- 交叉：子を生成する過程。集団内からランダムに親を選択し、設定された交叉率に従って、2 個の子を生成する。
- 突然変異：ある突然変異率で、遺伝子に突然変異を適用し、対立遺伝子に置き換える。
- 選択：選択は生物の自然淘汰をモデル化したもので、適応度にもとづいて個体数を増減する操作である。

各遺伝的操作を一回適用する期間を世代と呼ぶ。

#### 4.2 Thermodynamical Genetic Algorithm

本研究では、GA における選択プロセスに熱力学的なエントロピーと温度の概念を導入した熱力学遺伝アルゴリズム (Thermodynamical Genetic Algorithm : TDGA) [森 96] を使用する。このアルゴリズムは、遺伝的操作の選択を主に改良したものであり、良い個体が選択で次の世代に選ばれやすく、比較的似た遺伝子配列を持つことによって世代の多様性が失われることを防ぐ。そして、適応度が高い個体を残し、かつ世代の多様性を残すために熱力学的選択ルールを導入している。

##### 4.2.1 多様性

個体群中の個体の種 (多数の遺伝子座中の 1 遺伝子座でも遺伝子が異なっていれば異なる種と考える) についてのエントロピー  $H^{\text{ALL}}$  は、次式で表される。

$$H^{\text{ALL}} = - \sum_i p_i \log p_i \quad (1)$$

ここで  $p_i$  は種  $i$  の存在確率である。全遺伝子座を一括して扱ったエントロピーであることから  $H^{\text{ALL}}$  と記してある。しかし、対立遺伝子を  $\{0, 1\}$ 、遺伝子長を 10 とした場合、1024 種類の個体があることになり、1 世代の個体数に比べて極めて大きい。従って、1 つの世代に含まれる個体の種類はごく一部であり、それぞれを個別個体として扱うのは難しい。(1) 式をそのまま用いることは現実的でないため、代わりに次式のように各遺伝子座ごとにエントロピーを計算する方法を用いる。

$$H^1 = \sum_{k=1}^M H_k^1, \quad H_k^1 = - \sum_{j \in \{0,1\}} P_j^k \log P_j^k \quad (2)$$



図 2: 実験データとして用いる私物のファッションアイテム

表 1: TDGA の設定

交叉	一様交叉 確率 0.5
突然変異率	遺伝子座ごとに 0.05
個体数 $N$	32
温度 $T$	0.0001 - 1
最終世代数	200
着回し期間	10 日間

ここで、1 遺伝子座ごとに考えたエントロピーであるので  $H^1$  と記した。  $M$  は遺伝子長である。また簡単のため対立遺伝子を 2 値  $\{0, 1\}$  とした。また  $H_k^1$  は個体群の遺伝子座  $k$  の遺伝子に関するエントロピーを、  $P_j^k$  は遺伝子座  $k$  における対立遺伝子  $j$  の存在確率を表している。このように遺伝子座ごとに管理することで、対立遺伝子の種類の数のみの扱いで済み、困難であった個体群のエントロピーの評価を遺伝子座毎のエントロピーの総和と置き換えることで計算できるようになった。

##### 4.2.2 熱力学的選択ルール

TDGA における選択の際の指標は次式で表される。

$$F = \langle E \rangle - HT \quad (3)$$

ここで、  $F$  は自由エネルギーであり、最小化を目指す。また、  $\langle E \rangle$  は系の平均エネルギー、  $H$  はエントロピー、  $T$  は温度と呼ばれる正のパラメータである。  $\langle E \rangle$  は適応度を維持する項で、  $HT$  は多様度を維持する項である。選択の際は、ある個体を加えた時にできる個体集団において上記の  $F$  を計算し、最も小さくなるような個体を加えるということを繰り返す。

### 5. 数値実験 1

#### 5.1 実験内容

図 2 に示すように、著者の私物のアイテムからトップス、ボトムス、シューズを 5 個ずつ用意し、計 15 着で着まわしプランを作成する。まずトップス、ボトムス、シューズの組合せ全通りを先行研究 [Han 17] のモデルに入力し、コーディネートの出来栄え点 125 個を獲得する。この出来栄え点を用いてコーディネートスケジュールの組合せ最適化に TDGA を適用する。

表 2 に TDGA の設定を示す。個体表現に関しては、遺伝子長はトップス、ボトムス、シューズの 3 アイテム  $\times$  10 日間 = 30、対立遺伝子は各カテゴリのアイテムを示す 0 から 4 までの整数である。

TDGA における適応度については先行研究 [Han 17] のモデルの損失関数値の符号を変えた値を用いる。コーディネートアイテムの特徴量  $F = \{x_1, x_2, \dots, x_N\}$  を逐次入力した時、内

部状態を更新しながら次に入力されるアイテムを予測する。次のアイテムを予測できたか否かでモデルを評価するため、コスト関数は以下のようにソフトマックスで定義されている。

- 前向き LSTM

$$E_f(F; \theta_f) = -\frac{1}{N} \sum_{t=1}^N \log P_r(x_{t+1}|x_1, \dots, x_t; \theta_f) \quad (4)$$

$$P_r(x_{t+1}|x_1, \dots, x_t; \theta_f) = \frac{\exp(h_t x_{t+1})}{\sum_{x \in \chi} \exp(h_t x)} \quad (5)$$

- 後向き LSTM

$$E_b(F; \theta_b) = -\frac{1}{N} \sum_{t=N-1}^0 \log P_r(x_t|x_N, \dots, x_{t+1}; \theta_b) \quad (6)$$

$$P_r(x_t|x_N, \dots, x_{t+1}; \theta_b) = \frac{\exp(\tilde{h}_{t+1} x_t)}{\sum_{x \in \chi} \exp(\tilde{h}_{t+1} x)} \quad (7)$$

ここで、 $\theta_f, \theta_b$  はそれぞれ前向き LSTM, 後向き LSTM のパラメータ、 $\chi$  は候補となるアイテム画像の集合である。ロス  $E_f$  と  $E_b$  が小さいほどコーディネート の完成度が高いといえるため、 $E_f$  と  $E_b$  の和の負値をとることで、大きいほどコーディネート の完成度が高いという最大化問題に変換する。

コーディネートスケジュールに関して以下のペナルティを設定している。

- 10 日間のうちに同じコーディネートが 1 つでもあれば 1 点減点。
- $n$  日間連続して同じアイテムを使っていれば  $2^n$  点減点。(但し  $n \geq 2$ )
- 1 日飛ばして同じアイテムを使っていれば  $2^{1.5}$  点減点。
- 10 日間一度も使用されていないアイテムが存在すれば未使用アイテム数  $\times 2$  点減点。

これによって、偏りの無いようにアイテムを使い、バリエーション豊かなコーディネートスケジュールになることを目指す。

## 5.2 実験結果

図 3 に温度パラメータの変化によるコーディネート の総合点の推移を示す。縦軸は各コーディネート の出来栄点を 0 から 1 の値になるように標準化した総合点で、横軸は温度  $T$  である。縦軸の総合点は各温度で 10 回ずつ実行した時の平均値をとっている。 $T = 0.1$  の時に 7.724 点となり、総合点が最も高くなっている。

図 4 に最終世代で提案された最も総合点の高いコーディネートスケジュールを示す。温度が低い時と高いときのプランの差として  $T = 0.0001$  と  $T = 1$  の時を比較した。枠で囲った 2 つのコーディネートが共通していたが、黒い花柄のスカートの出現頻度が 2 から 4 に増えていたが、その他のアイテムの出現頻度あまり差は見られなかった。続いて、図 5 に最終世代での各コーディネート の着用回数のグラフを示す。横軸は 125 個のコーディネート を左からコーディネート 出来栄点の高いもの順に並べている。縦軸は各コーディネート の最終世代での着用回数である。 $T = 0.0001$  の時は、点が高いコーディネート を頻繁に使用しているが、 $T = 1$  の時は多様性を維持するために点が高いものから低いものまで均等に使用していることがわかる。




図 3: 温度パラメータの変化によるコーディネート の総合点の推移



図 4:  $T=0.0001, 1$  の時の最終世代で最も総合点の高いコーディネートスケジュール

## 6. 数値実験 2


### 6.1 実験内容

図 6 に示すように、実際は所持している各カテゴリのアイテム数は異なることを想定し、トップス 10 個、ボトムス 8 個、シューズ 7 個用意し、それに購入検討ボトムスを加え、推薦システムを提案する。


トップス、ボトムス、シューズの組合せ全通りを先行研究 [Han 17] のモデルに入力し、コーディネート の出来栄点 770 個を獲得する。この出来栄点を元に購入検討アイテムを一つずつ手持ちアイテムに追加し TDGA を適用する。但し、コーディネートスケジュールの比較をしやすいするため 1 日目のコーディネート を手持ちのアイテムの組合せの中で最も点数の高いコーディネート に固定した。

表 2 に TDGA の設定を示す。個体表現に関しては、遺伝子長はトップス、ボトムス、シューズの 3 アイテム  $\times$  21 日間 (固定のコーディネート + 20 日分のコーディネートスケジュール) = 60, 対立遺伝子は各カテゴリのアイテムを示す整数 (トップスであれば 0 から 9 まで) である。ペナルティは数値実験 1 と同様である。

手持ちアイテムのみの場合、候補 1 を加えた場合、候補 2 を加えた場合、候補 3 を加えた場合の実験をそれぞれ 10 回ずつ試行し、手持ちアイテムのみの時の結果とそれぞれ候補を加えた時の結果を、2 つの標本の平均値に有意差がないこと帰無仮説とした  $t$  検定により比較し、有意確率が 5% で棄却され、かつ最小の結果を出したアイテムを推薦することとする。



[1]  $T=0.0001$



[2]  $T=1$

図 5: 最終世代での各コーディネートでの着用回数

表 2: TDGA の設定

交叉	一様交叉 確率 0.5
突然変異率	遺伝子座ごとに 0.05
個体数 $N$	32
温度 $T$	0.01
最終世代数	200
着回し期間	20 日間

また、どの候補アイテムを加えた場合も 5% で棄却できなかった場合は、最終世代の最良個体内での候補アイテムの出現頻度が最も高いものを推薦する。

## 6.2 実験結果

表 3 に各購入検討ボトムスを加えて 10 回試行した平均点、標準偏差、 $t$  検定による有意確率  $p$  値を示す。 $p$  値が 5% を切っているものは候補 2 を含めた場合のみであるため、今回推薦するアイテムは候補 2 ということになる。図 7 に候補 2 を加えた時の最終世代の最良個体を示す。著者の主観にはなるが、3 つの候補の中で最も好ましいアイテムが選択されるという結果になった。

表 3: 10 回試行における  $t$  検定による有意確率  $p$  値

	10 回平均	標準偏差	$p$ 値
手持ちの服のみでの着まわし実験	16.45	0.154	-
候補 1 を含めた実験	16.60	0.264	0.152
候補 2 を含めた実験	16.27	0.194	0.040
候補 3 を含めた実験	16.48	0.167	0.708



図 6: 実験データとして用いる私物のファッションアイテムと購入検討ボトムス



図 7: 手持ちアイテムのみ時と候補 2 を加えた時の最終世代の最良個体

## 7. まとめと今後の課題

本研究では、ファッションを学習した学習器によりコーディネートの出来栄え点を獲得し、それを用いてコーディネートスケジュールを最適化する手法を提案した。この手法を用いて、手持ちのアイテムに合ったアイテムを推薦することもできるため、手持ちのアイテムとどう合わせたらよいか考えながら購入を検討するユーザには良い購買支援システムになることが示唆された。また、今回は新しいアイテムを購入することにより今までの服装とイメージを変えたいのか、あまり変えずにオシャレになりたいのかということは検討していないため、コーディネートスケジュール間の独自の距離指標を設け、ユーザの選択によりアイテムの推薦が変わる仕様に変えていきたい。

## 参考文献

- [Gers 99] Gers, F. A., Schmidhuber, J., and Cummins, F.: Learning to Forget: Continual Prediction with LSTM, *Neural Computation*, Vol. 12, pp. 2451–2471 (1999)
- [Han 17] Han, X., Wu, Z., Jiang, Y.-G., and Davis, L. S.: Learning Fashion Compatibility with Bidirectional LSTMs, in *ACM Multimedia* (2017)
- [森 96] 森, 吉田, 喜多, 西川: 遺伝アルゴリズムにおける熱力学的選択ルールの提案, システム制御情報学会論文誌, Vol. 9, No. 2, pp. 82–90 (1996)