

## 遺伝的アルゴリズムを用いたファッションコーディネートプランの最適化

### 1 はじめに

近年、機械学習の発展を背景として人工知能 (Artificial Intelligence : AI) が注目を浴びている。その中でも特に画像認識の分野は物体識別や顔検出など実社会における応用範囲が広く、関連研究が積極的になされている。AI は単純なパターン認識では人間の能力を凌駕する一方で、人間の感性に関する分野への AI の適用はいまだに難しく AI 研究の重要な課題とされている。一方、近年様々な国際会議において、ファッション関連技術を扱うワークショップが催されるようになり、ファッションに対する画像認識技術への関心が高まりつつある。ファッション分野は人間の感性の多様性や主観を多く含む対象なので工学的には積極的には研究されてこなかったが、認識技術の高度化・データセットの充実・産業界の需要の増加などの要因で研究事例も増加傾向にある。衣服のトレンドは時系列解析、衣服のコーディネートは組合せ最適化問題というように、ファッションは工学的に広汎な研究テーマを内包している。以上の点を背景として本研究は、複数の衣服やアクセサリの画像で構成されたコーディネート进行学习したモデルからコーディネートの出来栄え点を獲得し、それを用いてファッションコーディネートプランを最適化することを目的としている。

### 2 先行研究

コーディネートの出来栄えを評価する先行研究として、Han らの研究 [1] について述べる。図 1 に示すように、畳み込みニューラルネットワークにより抽出したファッションアイテム画像の特徴量を再帰型ニューラルネットワークの一種である Long short-term memory (LSTM) [2] の入力とし、次のアイテムを予測できたか否かで評価するモデルを提案している。

#### 2.1 データセット

先行研究 [1] で用いられているデータセット「Polyvore Dataset」について述べる。Polyvore は EC サイトの服の画像を、ユーザがコラージュして投稿するサービスで、同サイトの投稿を収集したものが Polyvore Dataset である。




図 1: 先行研究 [1] (図 2 を参照) のモデル概略図

Polyvore Dataset ではアイテムがおおよそ種別の順番に並んでおり、トップス、ボトムス、靴、アクセサリの順になっている。トップスの中でも、シャツや T シャツはアウターの前に来るように配置されている。また、アクセサリも概ねハンドバッグ、帽子、メガネ、時計、ネックレス、イヤリングなどの順に並んでおり、トップスから順に index が振られていく。このため index が大きくなるに従って、アイテム種別はだまかに定まるが、一意には対応していない。

このデータセットには 21,889 のコーディネートがある。1 つのコーディネートに含まれるアイテムの数は各コーディネートによって異なるため、アイテム数の上限が 8 になるように揃えられている。

#### 2.2 応用問題

先行研究のモデルでコーディネートを学習することによって、以下のような問題を解くことができる。

- コーディネートの出来栄えを採点する。
- コーディネートに欠けているアイテムを選択する。
- 与えられたファッションアイテムに合ったコーディネートを生成する。

### 3 提案手法

先行研究では 1 つのコーディネートについてのみ検討・評価していたため、複数の期間にわたるコーディネートプランについては言及されていなかった。そこで本研究

では、ファッションアイテムの定量化および評価に先ほどの先行研究のモデルを用いてコーディネートの出来栄点を獲得し、遺伝的アルゴリズムを用いて複数のコーディネートプランからなるリストつまり、着まわしプランを作成するシステムを提案する。

## 4 要素技術

### 4.1 遺伝的アルゴリズム

遺伝的アルゴリズム (Genetic Algorithm : GA) とは生物進化における遺伝と適者生存における自然淘汰の仕組みをソフトウェア的に模倣することで複雑な問題に対する最適解を探索する手法である。ここでは本研究で用いた GA の設定について説明する。まず  $N$  個の個体からなる初期集団を発生させ、各個体の適応度を計算する。通常、各遺伝子の値はランダムに初期化される。

GA では一般的に次の遺伝的操作が用いられる。

- 交叉：子を生成する過程。集団内からランダムに親を選択し、設定された交叉率に従って、2 個の子を生成する。
- 突然変異：ある突然変異率で、遺伝子に突然変異を適用し、対立遺伝子に置き換える。一般的に、突然変異は、局所的最適解からの脱出に効果がある。しかし、突然変異率を大きくすると、ランダム探索に近い状態になるため、通常、小さな値が使用される。
- 選択：選択は生物の自然淘汰をモデル化したもので、適応度にもとづいて個体数を増減する操作である。

各遺伝的操作を一回適用する期間を世代と呼ぶ。

### 4.2 Thermodynamical Genetic Algorithm

本研究では、GA における選択プロセスに熱力学的なエントロピーと温度の概念を導入した熱力学遺伝アルゴリズム (Thermodynamical Genetic Algorithm : TDGA) を使用する。このアルゴリズムは、遺伝的操作の選択を主に改良したものであり、良い個体が選択で次の世代に選ばれやすく、比較的似た遺伝子配列を持つことによって世代の多様性が失われることを防ぐ。そして、適応度が高い個体を残し、かつ世代の多様性を残すために熱力学的選択ルールを導入している。

#### 4.2.1 多様性

個体群中の個体の種 (多数の遺伝子座中の 1 遺伝子座でも遺伝子が異なっていれば異なる種と考える) についてのエントロピー  $H^{\text{ALL}}$  は、次式で表される。

$$H^{\text{ALL}} = - \sum_i p_i \log p_i \quad (1)$$

ここで  $p_i$  は種  $i$  の存在確率である。全遺伝子座を一括して扱ったエントロピーであることから  $H^{\text{ALL}}$  と記してある。しかし、対立遺伝子を  $\{0, 1\}$ 、遺伝子長を 10 とした場合、1024 種類の個体があることになり、1 世代の個体数に比べて極めて大きい。従って、1 つの世代に含まれる個体の種類はごく一部であり、それぞれをユニークな個体として扱うのは難しい。(1) 式をそのまま用いることは現実的でないため、代わりに次式のように各遺伝子座ごとにエントロピーを計算する方法を用いる。

$$H^1 = \sum_{k=1}^M H_k^1, \quad H_k^1 = - \sum_{j \in \{0,1\}} P_j^k \log P_j^k \quad (2)$$

ここで、1 遺伝子座ごとに考えたエントロピーであるので  $H^1$  と記した。 $M$  は遺伝子長である。また簡単のため対立遺伝子を 2 値  $\{0, 1\}$  とした。また  $H_k^1$  は個体群の遺伝子座  $k$  の遺伝子に関するエントロピーを、 $P_j^k$  は遺伝子座  $k$  における対立遺伝子  $j$  の存在確率を表している。このように遺伝子座ごとに管理することで、対立遺伝子の種類の数のみの扱いで済み、困難であった個体群のエントロピーの評価を遺伝子座毎のエントロピーの総和と置き換えることで計算できるようになった。

#### 4.2.2 熱力学的選択ルール

TDGA では探索効率を落とすことなく、熱力学的理論によって多様性を維持する狙いがある。選択の際の指標は次式で表される。

$$F = \langle E \rangle - HT \quad (3)$$

ここで、 $F$  は自由エネルギーであり、最小化を目指す。また、 $\langle E \rangle$  は系の平均エネルギー、 $H$  はエントロピー、 $T$  は温度と呼ばれる正のパラメータである。 $\langle E \rangle$  は適応度を維持する項で、 $HT$  は多様性を維持する項である。選択の際は、ある個体を加えた時にできる個体集団において上記の  $F$  を計算し、最も小さくなるような個体を加えるということを繰り返す。



図 2: 実験データとして用いる私物のファッションアイテム

表 1: TDGA の設定		
交叉	一様交叉	確率 0.5
突然変異率	遺伝子座ごとに	0.05
個体数 $N$		32
温度 $T$		0.1-10
最終世代数		400
着回し期間		10 日間

## 5 実験内容

図 2 に示すように、私物のアイテムからトップス、ボトムス、シューズを 5 個ずつ用意し、計 15 着で着まわしプランを作成する。まずトップス、ボトムス、シューズの組合せ全通りを先行研究 [1] のモデルに入力し、コーディネートが出来栄え点 125 個を獲得する。この出来栄え点を元に GA を適用する。

表 1 に TDGA の設定を示す。個体表現に関しては、遺伝子長はトップス、ボトムス、シューズの 3 アイテム  $\times$  10 日間 = 30, 対立遺伝子は各カテゴリのアイテムを示す 0 から 4 までの整数である。図 3 に遺伝子型の具体例を示す。

GA での指標となる適応度については先行研究 [1] のモデルのロスにマイナスをかけたものをコーディネートが出来栄え点として扱っている。コーディネートアイテムの特徴量  $F = \{x_1, x_2, \dots, x_N\}$  を逐次入力した時、内部状態を更新しながら次に入力されるアイテムを予測する。次のアイテムを予測できたか否かでモデルを評価するため、コスト関数は以下のようにソフトマックスで定




図 3: 個体の具体例

義されている。

- 前向き LSTM

$$E_f(F; \theta_f) = -\frac{1}{N} \sum_{t=1}^N \log P_r(x_{t+1} | x_1, \dots, x_t; \theta_f) \quad (4)$$

$$P_r(x_{t+1} | x_1, \dots, x_t; \theta_f) = \frac{\exp(h_t x_{t+1})}{\sum_{x \in \chi} \exp(h_t x)} \quad (5)$$

- 後向き LSTM

$$E_b(F; \theta_b) = -\frac{1}{N} \sum_{t=N-1}^0 \log P_r(x_t | x_N, \dots, x_{t+1}; \theta_b) \quad (6)$$

$$P_r(x_t | x_N, \dots, x_{t+1}; \theta_b) = \frac{\exp(\tilde{h}_{t+1} x_t)}{\sum_{x \in \chi} \exp(\tilde{h}_{t+1} x)} \quad (7)$$

ここで、 $\theta_f, \theta_b$  はそれぞれ前向き LSTM, 後向き LSTM のパラメータ、 $\chi$  は候補となるアイテム画像の集合である。ロス  $E_f$  と  $E_b$  が小さいほどコーディネートの完成度が高いと言えるため、 $E_f$  と  $E_b$  を足したもののマイナスをとることで、大きいほどコーディネートの完成度が高いというコーディネートの出来栄え点を得ることができる。

コーディネートプランに関して以下のペナルティを設定している。

- 10 日間のうちに同じコーディネートが 2 回以上出現。
- 3 日以内に同じアイテムを使用。
- 10 日間一度も使用されていないアイテムが存在。

上記の条件に該当するたびに -1 のペナルティを課す。ペナルティによって、偏りの無いようにアイテムを使い、バリエーション豊かなコーディネートプランになることを目指す。

## 6 実験結果

図 4 に温度パラメータの変化によるコーディネートの総合点の推移を示す。縦軸は各コーディネートの点数を




図 4: 温度パラメータの変化によるコーディネートの総合点の推移



図 5:  $T=0.1$ , 10 の時の最終世代で最も総合点の高いコーディネートプラン

0 から 1 の値になるように標準化した総合点で、横軸は温度  $T$  である。縦軸の総合点は各温度で 5 回ずつ実行した時の平均値をとっている。  $T = 0.1$  の時に 8.386 点となり、総合点が最も高くなっている。

図 5 に最終世代で提案された最も総合点の高いコーディネートプランを示す。温度が低い時と高いときのプランの差として  $T = 0.1$  と  $T = 10$  の時を比較した。枠で囲った 4 つのコーディネートが共通していたが、各アイテムの出現頻度により差は見られなかった。続いて、図 6 に最終世代での各コーディネートの着用回数のグラフを示す。横軸は 125 個のコーディネートを左からコーディネート出来栄え点の高いもの順に並べている。縦軸は各コーディネートの最終世代での着用回数である。  $T = 0.1$  の時は、点が高いコーディネートを頻繁に使用しているが、  $T = 10$  の時は多様性を維持するために点が高いものから低いものまで均等に使用していることがわかる。

## 7 考察・今後の課題

温度が低い方が同世代内の多様性を考慮しないためコーディネート総合点が高く、個体内の多様性に関してはペ

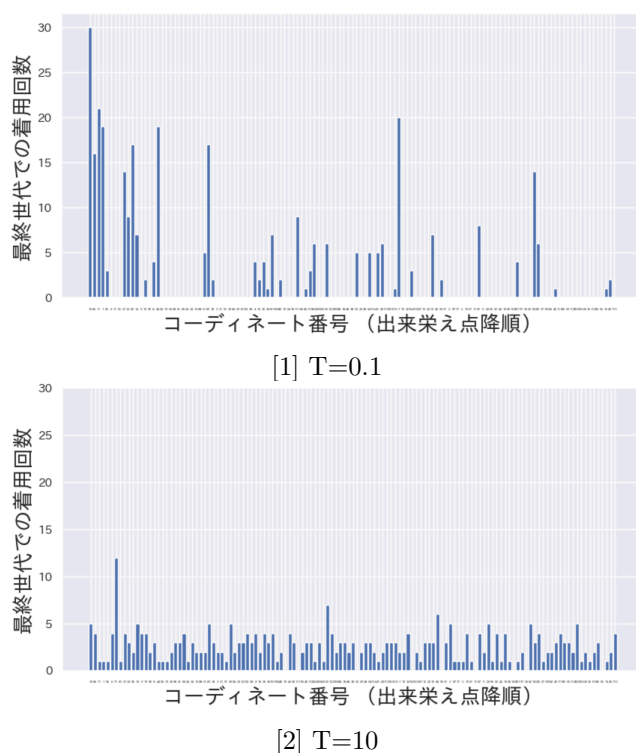


図 6: 最終世代での各コーディネートの着用回数

ナルティを与えているため、アイテムの偏りも見られない。また、手持ちの服は大体系統が似通っているため、不満足なコーディネートが出てくる方が少ないという、元々自分の趣味嗜好によるバイアスがかかった結果が得られる。従って今後の応用としては、持っていないアイテムを混ぜて、手持ちのアイテムと相性が良く、着まわしやすい商品が何かを推薦するツールとしての活用が挙げられる。また、コーディネートの出来栄え点を算出する今回用いた Han ら [1] のモデルは 2017 年のモデルであるため、より性能の良い最新のモデルを試す必要がある。

## 参考文献

- [1] Xintong Han, Zuxuan Wu, Yu-Gang Jiang, and Larry S Davis. Learning fashion compatibility with bidirectional lstms. In *ACM Multimedia*, 2017.
- [2] Felix A. Gers, Jürgen Schmidhuber, and Fred Cummins. Learning to forget: Continual prediction with lstm. *Neural Computation*, 12:2451–2471, 1999.
- [3] N. MORI. A thermodynamical selection rule for the genetic algorithm. *Proc. of 2nd IEEE Conference on Evolutionary Computation*, 1995, 1995.