

熱力学的遺伝アルゴリズムおよび Bi-LSTM + VSE に基づくコーディネートスケジュールの最適化

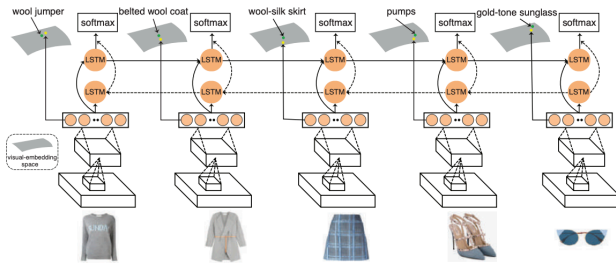


図 1: 先行研究 [1] (図 2 を参照) のモデル概略図

1 はじめに

近年、機械学習の発展を背景として人工知能 (Artificial Intelligence: AI) が注目を浴びている。その中でも特に画像認識の分野は実社会における応用範囲が広く、関連研究が積極的になされている。AI は単純なパターン認識では人間の能力を凌駕する一方で、人間の感性に関する分野への AI の適用はいまだに難しく重要な課題とされている。以上の点を背景として本研究は、複数の衣服やアクセサリの画像で構成されたコーディネート进行学习したモデルからコーディネートの出来栄え点を獲得し、それを用いてファッションコーディネートスケジュールを最適化する手法を提案する。また数値実験により、提案手法がユーザが購入を検討しているアイテムを定量的に評価し、どのアイテムを買うべきか推薦するツールとしても活用できることを示す。

2 関連研究

2.1 先行研究

コーディネートの出来栄えを評価する先行研究として、Han らの研究 [1] について述べる。図 1 に示すように、畳み込みニューラルネットワークにより抽出したファッションアイテム画像の特徴量を再帰型ニューラルネットワークの一種である Long short-term memory (LSTM) [2] の入力とし、次のアイテムを予測できたか否かで評価するモデルを提案している。

2.2 データセット

先行研究 [1] で用いられているデータセット「Polyvore Dataset」について述べる。Polyvore は EC サイトの服の画像を、ユーザがコラージュして投稿するサービスで、同サイトの投稿を収集したものが Polyvore Dataset である。

Polyvore Dataset ではアイテムがおおよそ種別の順番に並んでおり、トップス、ボトムス、靴、アクセサリの順になっている。トップスの中でも、シャツや T シャツはアウターの前に来るように配置されている。また、アクセサリも概ねハンドバッグ、帽子、メガネ、時計、ネックレス、イヤリングなどの順に並んでおり、トップスから順に index が振られていく。このため index が大きくなるに従って、アイテム種別は大まかに定まるが、一意には対応していない。

このデータセットには 21,889 のコーディネートがある。1 つのコーディネートに含まれるアイテムの数は各コーディネートによって異なるため、アイテム数の上限が 8 になるように揃えられている。

2.3 適用事例

2.1 で示した先行研究のモデルでコーディネートを学習することによって、以下のような問題を解くことができる。

- コーディネートの出来栄えを採点する。
- コーディネートに欠けているアイテムを選択する。
- 与えられたファッションアイテムに合ったコーディネート生成する。

3 提案手法

先行研究では 1 つのコーディネートについてのみ検討・評価していたため、複数の期間にわたるコーディネートスケジュールについては言及されていなかった。そこで本研究では、コーディネートの定量的評価に先述の先行研究のモデルを用いてコーディネートの出来栄え点を獲得し、遺伝的アルゴリズムを用いて複数のコーディネートからなるコーディネートスケジュールを作成するシステムを提案する。

4 要素技術

4.1 遺伝的アルゴリズム

遺伝的アルゴリズム (Genetic Algorithm : GA) とは生物進化における遺伝と適者生存における自然淘汰の仕組みを取り入れた最適化手法である。ここでは本研究で用いた GA の設定について説明する。まずランダムに初期化された N 個の個体からなる初期集団を発生させ、各個体の適応度を計算する。

GA では一般的に次の遺伝的操作が用いられる。

- 交叉 : 子を生成する過程。集団内からランダムに 2 個体を親として選択し、設定された交叉率に従って、2 個の子を生成する。
- 突然変異 : ある突然変異率で、遺伝子に突然変異を適用し、対立遺伝子に置き換える。
- 選択 : 選択は生物の自然淘汰をモデル化したもので、適応度に基づいて個体数を増減する操作である。

各遺伝的操作を一回適用する期間を世代と呼ぶ。

4.2 Thermodynamical Genetic Algorithm

本研究では、GA における選択プロセスに熱力学的なエントロピーと温度の概念を導入した熱力学遺伝アルゴリズム (Thermodynamical Genetic Algorithm: TDGA) [3] を使用する。このアルゴリズムは、遺伝的操作の選択を主に改良したものであり、良い個体が選択で次の世代に選ばれやすく、比較的似た遺伝子配列を持つことによって世代の多様性が失われることを防ぐ。そして、適応度が高い個体を残し、かつ世代の多様性を残すために熱力学的選択ルールを導入している。

4.2.1 多様性

個体群中の個体の種 (多数の遺伝子座中の 1 遺伝子座でも遺伝子が異なっていれば異なる種と考える) についてのエントロピー H^{ALL} は、次式で表される。

$$H^{\text{ALL}} = - \sum_i p_i \log p_i \quad (1)$$

ここで p_i は種 i の存在確率である。全遺伝子座を一括して扱ったエントロピーであることから H_{ALL} と記してある。しかし、対立遺伝子を $\{0, 1\}$ 、遺伝子長を 10 とした場合、1024 種類の個体があることになり、1 世代の個体数に比べて極めて大きい。従って、1 つの世代に含まれる個体の種類はごく一部であり、それぞれを個別個体と

して扱うのは難しい。(1) 式をそのまま用いることは現実的でないため、代わりに次式のように各遺伝子座ごとにエントロピーを計算する方法を用いる。

$$H^1 = \sum_{k=1}^M H_k^1, \quad H_k^1 = - \sum_{j \in \{0,1\}} P_j^k \log P_j^k \quad (2)$$

ここで、1 遺伝子座ごとに考えたエントロピーであるので H^1 と記した。 M は遺伝子長である。また簡単のため対立遺伝子を 2 値 $\{0, 1\}$ とした。また H_k^1 は個体群の遺伝子座 k の遺伝子に関するエントロピーを、 P_j^k は遺伝子座 k における対立遺伝子 j の存在確率を表している。このように遺伝子座ごとに管理することで、対立遺伝子の種類の数のみの扱いで済み、困難であった個体群のエントロピーの評価を遺伝子座毎のエントロピーの総和と置き換えることで計算できるようになった。

4.2.2 熱力学的選択ルール

TDGA における選択の際の指標は次式で表される。

$$F = \langle E \rangle - HT \quad (3)$$

ここで、 F は熱力学において自由エネルギーと呼ばれる値であり、平衡状態で最小となることが知られている。また、 $\langle E \rangle$ は系の平均エネルギー、 H はエントロピー、 T は温度と呼ばれる正のパラメータである。 $\langle E \rangle$ は適応度を評価する項で、 HT は多様度を維持する項である。選択の際は、ある個体を加えた場合にできる個体集団において上記の F を計算し、最も小さくなるような個体を加えるということを繰り返す。

5 実験内容

図 2 に示すように、実際は所持している各カテゴリのアイテム数は異なることを想定し、トップス 10 個、ボトムス 8 個、シューズ 7 個用意し、それに購入検討ボトムスを加え、推薦システムを提案する。

トップス、ボトムス、シューズの組合せ全通りを先行研究 [1] のモデルに入力し、コーディネートの出来栄え点 770 個を獲得する。この出来栄え点を元に購入検討アイテムを一つずつ手持ちアイテムに追加し TDGA を適用する。但し、コーディネートスケジュールの比較をしやすくするため 1 日目のコーディネートを手持ちのアイテムの組合せの中で最も点数の高いコーディネートに固定した。

表 1 に TDGA の設定を示す。交叉率、個体内のコーディネートの交叉率、突然変異率や温度は、Optuna に



図 2: 実験データとして用いる私物のファッションアイテムと購入検討ボトムス

表 1: TDGA の設定

交叉 (一様交叉)	0.01 ~ 1
個体内のコーディネート交叉率	0.01 ~ 1
突然変異率	0.0001 ~ 0.1
温度 T	0.01 ~ 1
個体数 N	32
最終世代数	200
着回し期間	21 日間

よりパラメータ調整をするため探索範囲を示す。個体表現に関しては、遺伝子長はトップス、ボトムス、シューズの 3 アイテム \times 21 日間 (固定のコーディネート + 20 日分のコーディネートスケジュール) = 63, 対立遺伝子は各カテゴリのアイテムを示す整数 (トップスであれば 0 から 9 まで) である。

5.1 TDGA における適応度

TDGA における適応度については先行研究 [1] のモデルの損失関数値の符号を変えた値を用いる。この場合、TDGA のエネルギーは損失関数値となる。コーディネートアイテムの特徴量 $F = \{x_1, x_2, \dots, x_N\}$ を逐次入力し、内部状態を更新しながら次に入力されるアイテムを予測する。次のアイテムを予測できたか否かでモデルを評価するため、損失関数は以下のソフトマックスで定義されている。

- 前向き LSTM

$$E_f(F; \theta_f) = -\frac{1}{N} \sum_{t=1}^N \log P_r(x_{t+1}|x_1, \dots, x_t; \theta_f) \quad (4)$$

$$P_r(x_{t+1}|x_1, \dots, x_t; \theta_f) = \frac{\exp(h_t x_{t+1})}{\sum_{x \in \chi} \exp(h_t x)} \quad (5)$$

- 後向き LSTM

$$E_b(F; \theta_b) = -\frac{1}{N} \sum_{t=N-1}^0 \log P_r(x_t|x_N, \dots, x_{t+1}; \theta_b) \quad (6)$$

$$P_r(x_t|x_N, \dots, x_{t+1}; \theta_b) = \frac{\exp(\tilde{h}_{t+1} x_t)}{\sum_{x \in \chi} \exp(\tilde{h}_{t+1} x)} \quad (7)$$

ここで、 θ_f, θ_b はそれぞれ前向き LSTM, 後向き LSTM のパラメータ、 χ は候補となるアイテム画像の集合である。損失関数の E_f と E_b が小さいほどコーディネートの完成度が高いといえるため、 E_f と E_b の和の負値をとることで、大きいほどコーディネートの完成度が高いという最大化問題に変換する。

5.2 ペナルティとボーナス設定

コーディネートスケジュールに関して以下のペナルティを設定している。

- 10 日間のうちにコーディネートが重複していれば、重複数 - 1 点減点。
- n 日間連続して同じアイテムを使っていれば、 2^n 点減点。 (但し $n \geq 2$)
- 1 日飛ばして同じアイテムを使っていれば、 $2^{1.5}$ 点減点。
- 10 日間一度も使用されていないアイテムが存在すれば、未使用アイテム数 \times 2 点減点。

これによって、偏りの無いようにアイテムを使い、バリエーション豊かなコーディネートスケジュールになることを目指す。

ペナルティに加えて、購入検討アイテムをできるだけ多く使いながらコーディネートスケジュールを生成し比較するため、購入検討アイテムの使用回数に対して以下のボーナスを付与した。

$$\text{bonus} = \sin\left(\frac{\pi}{10}x\right)$$

使用回数が 5 で最大値 1 をとる関数である。

手持ちアイテムのみの場合、候補 1 を加えた場合、候補 2 を加えた場合、候補 3 を加えた場合の実験をそれぞれ 10 回ずつ試行し、候補アイテムをそれぞれ加えた場合の最良個体において候補アイテムの平均使用回数が最も多いものを推薦する。どの候補アイテムを加えた場合も平均使用回数が同じであった場合、コーディネートスケジュールの点数が最も高いものを推薦する。

5.3 初期個体群の構成方法

初期個体群の構成方法として、予め greedy 法によって得た解を入れる手法を提案する。一世代 32 個ある個体のうち 1 個体目は greedy 法で得たコーディネートスケ

表 2: Optuna によるパラメータの探索結果

交叉 (一様交叉)	0.504
個体内のコーディネート交叉率	0.227
突然変異率	0.022
温度 T	0.055




図 3: TDGA における適応度の min, max, mean の推移

ジュール, 2 個体目は ε -greedy 法で得たコーディネートスケジュール, 残りの 30 個体はランダムに生成した個体である. 2 個体目の ε -greedy 法では $\varepsilon = 0.2$ で 2 番目に点数が高くなるコーディネートを選択し解を得る.

6 実験結果

表 2 に Optuna によるパラメータの探索結果を, 図 3 に TDGA における適応度の min, max, mean の推移の様子を示す. 図 3 の横軸は世代数, 縦軸は適応度であるコーディネートスケジュールの点数を表している. 初期の地点で高い点数から始まっており, 初期の立ち上がりが早く, さらにそこから学習が進んでいることがわかる.

表 3 に各購入検討ボトムスを加えて 10 回試行した平均点, 標準偏差, 10 回試行の各最良個体での候補アイテムの使用回数の平均を示す. 平均使用回数が最も多く, コーディネートスケジュールの点数が最も高い結果となったのは候補 3 という結果になった. そのため今回推薦するアイテムは候補 3 の緑のパンツになる.

図 4 に手持ちアイテムのみの場合と候補 3 を加えた場合の最終世代の最良個体を示す. 著者の主観にはなるが, 手持ちのアイテムに似たものではなく, 差し色としてアクセントとなりセンスが上がってコーディネートの幅が大きく広がるアイテムを推薦することができたため, 多様性の観点から有効なコーディネートスケジュールの生成に成功していると考えられる.

表 3: TDGA 各 10 回試行の実験結果

	10 回平均	標準偏差	候補アイテム 使用回数の平均
手持ちの服のみでの実験	17.10	0.130	-
候補 1 を含めた実験	18.08	0.264	4.1
候補 2 を含めた実験	17.85	0.194	4.1
候補 3 を含めた実験	18.10	0.167	4.9



図 4: 最終世代における最良個体の比較

7 まとめと今後の課題

本研究では, ファッションを学習した学習器によりコーディネートが出来栄え点を獲得し, それを用いてコーディネートスケジュールを最適化する手法を提案した. この手法を用いて, 手持ちのアイテムに合ったアイテムを推薦することもできるため, 手持ちのアイテムとどう合わせたらよいか考えながら購入を検討するユーザには良い購買支援システムになることが示唆された. また, 今回は新しいアイテムを購入することにより今までの服装とイメージを変えたいのか, あまり変えずにオシャレになりたいのかということは検討していないため, コーディネートスケジュール間の独自の距離指標を設け, ユーザの選択によりアイテムの推薦が変わる仕様にしていきたい.

参考文献

- [1] Xintong Han, Zuxuan Wu, Yu-Gang Jiang, and Larry S Davis. Learning fashion compatibility with bidirectional lstms. In *ACM Multimedia*, 2017.
- [2] Felix A. Gers, Jürgen Schmidhuber, and Fred Cummins. Learning to forget: Continual prediction with lstm. *Neural Computation*, 12:2451–2471, 1999.
- [3] 森, 吉田, 喜多, and 西川. 遺伝アルゴリズムにおける熱力学的選択ルールの提案. システム制御情報学会論文誌, 9(2):82–90, 1996.